

基于狼人杀场景的 LLM 多智能体博弈、记忆与治理实验平台

以狼人杀的不完全信息、语言博弈、阵营对抗和投票决策为场景，构建可运行、可追踪、可复盘、可评测、可治理的多智能体实验闭环。

- 统一 Agent Harness
- Live / History / Memory / Reports
- 真实 LLM 批量报告
- Acceptance 证据待收口

0. 成果摘要

项目定位	基于狼人杀场景的 LLM 多智能体博弈、记忆与治理实验平台。
核心方法	统一 PlayerAgent + AgentHarness，角色差异由 Prompt、Observation 和 RuleEngine 驱动。
系统闭环	后端 GameEngine / Harness / Memory / Review / Reports；前端 Live / History / Memory / Reports。
工程证据	支持真实对局运行、历史回放、跨局记忆、批量报告、信息隔离和治理指标展示。
真实 LLM 证据	已有 17 局真实 LLM 批量运行报告、1,890 次 LLM 调用、约 389 万 token、fallback 率约 0.79%。
当前边界	真实 LLM 长批量运行、信息泄露样本复核、runtime artifact 自证明仍需继续收口。

REAL LLM GAMES	LLM CALLS	TOTAL TOKENS	FALLBACK RATE
17	1,890	3.89M	0.79%
批量报告中的真实 LLM 对局数。	用于对局发言、决策和治理链路。	约 3,897,251 tokens。	LLM 输出治理仍有可优化空间。

一、项目背景与问题定义

本项目以狼人杀作为多智能体实验场景，核心目标不是复刻一个游戏，而是利用多角色、不完全信息、公开发言、阵营对抗和投票裁决，验证 LLM Agent 在复杂规则环境下的推理、协作、欺骗识别、记忆积累和行为治理能力。

核心问题：如何让 LLM Agent 在严格信息隔离和规则约束下，完成可信、可追踪、可复盘、可评测的隐藏身份博弈。



图 1 狼人杀作为 Multi-Agent Arena 的场景价值图

信息不对称

不同角色拥有不同视角，系统必须保证 private / debug 信息不会进入 public timeline。

语言博弈

Agent 需要通过发言、质询和投票表达策略，而不是只执行静态动作。


可审计评测

对局过程需要沉淀为事件、决策、记忆和报告，支持后续追踪与治理。

成果证据链

报告采用“问题定义 → 统一 Agent 架构 → 系统运行闭环 → 前端证据视图 → 真实 LLM 评测 → 边界说明”的呈现路线，使成果从功能描述转为可验证证据。

基于狼人杀场景的 LLM 多智能体实验平台证据链



系统价值体现在可运行、可追踪、可复盘、可评测、可治理的完整闭环。

图 2 基于狼人杀场景的 LLM 多智能体实验平台证据链

二、核心方法：统一 Agent Harness

系统没有为狼人、预言家、女巫、猎人、守卫和平民分别硬编码独立 Agent，而是通过统一 PlayerAgent 入口承载所有角色，再由 Harness、角色策略、信息视角和规则裁决共同塑造差异化行为。



图 3 统一 Agent Harness 总体架构图

统一入口

```
PlayerAgent.act(game_state, context)
    observation = build_observation(player_id, view_mode)
    memory = retrieve_relevant_memory(agent_id, observation)
    decision = AgentHarness.run_turn(role, observation, memory)
    return decision.action
```

八阶段决策链路



阶段	作用	证明点
Observation	按角色和视角构造可见信息。	隔离 private / debug 信息。
Memory	注入跨局经验与历史行为摘要。	Agent 不是每局从零开始。
Prompt	注入角色目标、输出格式和约束。	角色差异由 Prompt 和策略驱动。
LLM Decision	生成发言、投票或夜间行动。	保留原始输出，支持审计。
Validation	解析、校验和修复动作。	避免非法动作直接进入 GameEngine。
Event Log	沉淀为事件、决策链和报告指标。	支撑 History / Reports 复盘。

角色差异的三层表达

差异来源	实现方式	示例
角色策略	RolePolicyFactory 选择策略类。	狼人伪装发言，预言家维护查验链。
信息视角	ObservationBuilder / InformationFilter 过滤信息。	狼人可见队友，平民只见公开信息。
动作空间	GameEngine.get_legal_targets() 限制动作。	预言家不能查验自己，守卫不能连守。
Prompt 约束	动态注入角色目标、禁令和输出格式。	狼人不能暴露队友，长期记忆不能当作身份事实。

LLM 输出治理机制



```
parse_and_validate(raw_output)
    action = parse_json_or_recover(raw_output)
    if not schema_valid(action):
        action = repair_or_fallback(action)
    if not legal_for_phase(action, game_state):
        action = deterministic_safe_action()
    record_decision(raw_output, repaired_action, fallback_reason)
```

三、系统闭环：从运行到复盘评测

统一 Harness 只解决 Agent 如何决策的问题。系统进一步将对局推进、动作校验、事件记录、记忆更新、复盘审计和批量评测串成闭环，使每次运行都能留下证据。



图 6 系统闭环总览：从对局执行到复盘评测

后端闭环

GameEngine 负责规则推进，Harness 负责 Agent 决策，Memory / Review / Reports 负责沉淀经验、复盘和指标。

前端闭环

Live 展示运行证据，History 展示过程证据，Memory 展示经验证据，Reports 展示评测证据。

治理闭环

visibility、fallback、invalid action、runtime artifact、memory coverage 都以指标形式显式暴露。

前端四视图承接系统证据链

统一的系统证据链（不同视角，互为印证）



Live 展示运行态，History 保留行为过程，Memory 记录长期经验，Reports 汇总实验结果，Review 提供异常治理证据。

图 7 前端四视图证据链：Live / History / Memory / Reports

视图	证据定位	回答的问题
Live	运行证据	系统是否真的能实时启动、推进和展示对局。
History	过程证据	公开事件、debug 决策和信息边界是否可追踪。
Memory	经验证据	Agent 是否具备跨局记忆覆盖与使用痕迹。
Reports	评测证据	系统是否以批量指标暴露质量、成本和治理风险。

四、运行证据与实验结果

本章不展开完整操作手册，只保留最能证明成果的界面证据。启动命令、API 配置和详细演示流程放入附录，正文聚焦“系统已经形成什么能力”。

4.1 Live 运行证据

Live 证明系统可以创建真实对局、选择 Agent 池、推进阶段、实时展示发言、总结、投票、出局和 LLM 调用状态。这里保留对局桌面总览与投票统计两张关键截图。



图 8 Live 运行总览：Agent 选择、对局桌面与实时工作区



图 9 投票流向与票数统计：从发言到裁决的过程证据

4.2 History 回放证据

History 将完成局拆成历史局列表、公开时间线和 Agent 决策记录。默认 public 视角只展示公开事件，debug 视角才展示 RolePolicy、Memory 注入、Fallback 修复和最终行动。




图 10 History 回放审计：public timeline 与 debug 决策边界

4.3 Memory 使用证据

Memory 展示 20 个 Agent 的覆盖矩阵、真实 LLM memory preflight、单 Agent Memory Dossier 和 usage timeline。它证明记忆不只是文件存储，而是可以追踪到检索、注入和使用记录。




图 11 Memory 治理：覆盖矩阵、Agent 档案与使用时间线

4.4 Reports 批量评测证据

Reports 汇总真实 LLM 报告、CI 门禁、Acceptance 状态、Primary Evidence Report、Leaderboard Snapshot 和 Memory Truth Audit。它的价值在于同时展示成果与风险，而不是只展示通过项。




图 12 Reports 评测审计：真实 LLM 证据、Acceptance 状态与治理指标

4.5 真实 LLM 运行结果摘要

指标	当前证据	说明
真实 LLM 对局	17 局	来自真实 LLM 批量报告，而非 FakeLLM 演示。
LLM 调用次数	1,890 次	覆盖发言、决策、修复和治理链路。
Token 使用量	3,897,251	用于说明真实运行规模与成本可度量。
Fallback	15 次，约 0.79%	说明输出治理机制被真实触发，也说明仍需优化。
Memory Usage	11,658 次	证明 Memory 参与 prompt retrieval / usage。
信息隔离	3 个样本需复核	Reports 已将风险显式暴露，后续需要逐条确认。

五、边界说明与后续优化

当前项目最重要的结论不是“没有风险”，而是已经具备把风险显式暴露出来的机制。工程质量已经形成闭环，真实 LLM 长批量运行、信息泄露样本复核和 runtime artifact 自证明，是后续重点收口项。

已完成能力

系统已具备可运行、可追踪、可复盘、可评测、可治理的基础能力。Live、History、Memory、Reports 四个视图分别承接运行证据、过程证据、经验证据和评测证据。

当前边界

CI 通过不等于 Acceptance 真实证据完全闭合。当前仍需要补强真实 LLM 长批量、多模型对照、runtime artifact、信息泄露复核和 Memory 有效性评估。

后续收口方向

方向	当前状态	后续目标
真实 LLM 长批量运行	已有真实 LLM 批量报告。	增加批次数、种子数和模型对照，形成稳定统计结论。
Acceptance 真实证据	已区分 CI 与 Acceptance。	补齐 runtime artifact、API 配置证明和 fail-fast 证明。
信息隔离审计	已暴露疑似泄露样本。	逐条复核，明确误报、prompt 泄露或事件 visibility 标注问题。
行为治理	已记录 fallback / invalid action。	按根因分类治理，降低非法动作比例。
Memory 有效性	已证明覆盖和使用。	增加 A/B 实验，证明 Memory 对策略质量的实际收益。
评测代表性	已有 Reports 指标。	扩展到多模型、多配置、多轮次统计。

附录：可复现说明与截图保留

A. 启动命令

```
make install  
make backend  
make frontend
```

后端默认地址为 `http://localhost:8000`，前端默认地址为 `http://localhost:3000`。如需检查后端状态，可访问 `/api/health`。

B. Agent / LLM API 配置

C. 主要接口

D. 演示操作流程

E. 截图保留画廊